

國立政治大學111學年度下學期

金融科技概論

期末報告（一）

利用LSTM神經網路預測以太幣幣價

指導教授：廖四郎 教授

學生：111753145 資科碩一 劉育佑

中華民國 112 年 6 月

摘要

本篇報告主旨在探討利用深度學習中RNN（遞迴神經網路, Recurrent Neural Network）系列模型中的LSTM演算法（長短期記憶模型, Long short-term memory）來預測以太幣價格的潛力。本篇報告將探討以太幣市場的背景和相關技術發展，並利用LSTM演算法在時間序列上分析、預測該領域的近期發展，提出一種以太幣價格預測模型，來幫助投資者或交易者做出決策，提升對於價格預測的準確度。

藉此報告，我們期望能夠深化對以太幣價格動態變化的理解，並同時驗證LSTM演算法在預測加密貨幣價格方面的有效性。這將有助於改善投資者的風險管理策略，提高交易者在交易決策準確性的部分，並為加密貨幣市場的未來發展提供非常寶貴的洞察力。

本篇報告架構將如下安排：首先，我們將介紹以太幣的背景以及重要性；接著，將回顧並展示與以太幣價格預測相關的文獻和方法；再來，會簡單介紹LSTM演算法的基本原理和近期的改進；最後，則將提出我們的預測模型並進行實驗結果的分析，並將對結果進行評估以及衍伸的研究與說明。

我們相信本篇報告的研究結果除了能將本學期的課程內容融會貫通、實際應用並作出結果的展示之外，也將為加密貨幣市場的參與者和研究人員提供有價值的見解，同時為LSTM演算法在預測加密貨幣價格方面的應用提供一個實證研究案例。

目錄

摘要	1
目錄	2
一、動機	3
二、以太坊介紹	4
2.1 以太坊的誕生與歷史	
2.2 以太坊的特點與應用	
2.2.1 智能合約	
2.2.2 去中心化應用 (DApps)	
2.2.3 ERC-20代幣標準	
2.3 以太坊的重要性	
2.3.1 技術創新	
2.3.2 社會影響	
三、LSTM演算法簡介	10
3.1 LSTM 發展歷程	
3.1.1 RNN的限制	
3.1.2 LSTM的提出	
3.1.3 LSTM的演進	
3.2 LSTM 特點	
3.2.1 長期依賴關係	
3.2.2 梯度穩定性	
3.2.3 多層結構	
3.3 LSTM 重要性	
四、實驗設計	14
4.1 資料來源	
4.2 程式碼	
4.3 結果分析與未來研究	
五、結論	18
參考資料	19

一、動機

在過去的數年裡，區塊鏈技術以及其衍伸應用—加密貨幣經歷了多次的變革、成長與衰退。其中，以太坊（Ethereum）的興起是世人重視的。作為一種開源的區塊鏈平台，以太坊不僅提供了一個去中心化的環境，也為開發者創造了無限的可能性。在以太坊生態系統中，以太幣（Ether）作為交易和智能合約執行的基本單位，扮演著關鍵的角色。

隨著以太坊的普及，以太幣的價格變得愈發重要。許多投資者、交易者和研究人員致力於預測以太幣價格的趨勢，以幫助他們做出更明智的決策。傳統的金融分析工具和技術已被廣泛應用，但隨著時間的推移，新興的機器學習和人工智慧技術開始在這個領域展現出巨大的潛力。

近年來，長短期記憶網絡（Long Short-Term Memory，LSTM）演算法在時間序列預測方面取得了引人注目的成果。LSTM是一種基於循環神經網絡（Recurrent Neural Network，RNN）的深度學習模型，具有捕捉長期依賴關係的能力，特別適用於處理時間序列數據。其獨特的結構和學習機制使其能夠有效地捕捉以太幣價格中的複雜模式和趨勢。

二、以太坊介紹

2.1 以太坊的誕生與歷史

以太坊（Ethereum）是自從比特幣之後最重要的區塊鏈項目之一，它在加密貨幣和區塊鏈技術領域扮演著重要角色。這個部分我們將回顧以太坊的誕生和發展歷程。

自從2008年比特幣白皮書的發布以來，開發者和科技社區開始研究和探索比特幣的區塊鏈技術。其中一位年輕的比特幣開發者，維塔利克·布特林（Vitalik Buterin），對於比特幣的局限性開始有所疑問，並提出了一個願景，希望創建一個更具靈活性和功能性的區塊鏈平台。

於是，2013年，布特林提出了以太坊的概念。他認為區塊鏈技術除了可以用於資金交易之外，還可以支持更廣泛的應用，例如智能合約（Smart Contract）和去中心化應用（DApps）。為了實現這一願景，布特林於2014年1月成立了以太坊基金會，並開始籌集資金進行項目開發。

以太坊的發展並非一帆風順。在2014年8月，以太坊的開發代碼公開發布，並進行了測試和改進。然而，由於技術和安全性方面的挑戰，以太坊的正式主網上線一再推遲。直到2015年7月，以太坊的主網才終於上線運行，開啟了以太坊的歷史新頁。

隨著以太坊的推出，開發者以及企業開始利用其強大的智能合約功能，這使得去中心化金融（DeFi）應用、非同質化代幣（NFT）市場和許多其他創新應用迅速崛起。以太坊成為了支持這些應用的首選平台，吸引了廣泛的開發者社區和投資者的關注。

然而，以太坊卻也面臨著一些挑戰。隨著應用需求的增長，以太坊的可擴展性問題浮出水面。交易速度變慢、交易費用飆升成為了瓶頸。為了解決這些問題，以太坊開發團隊進行了一系列的升級。

在2018年，以太坊實施了「拜占庭硬分叉」，引入了一些性能改進和新功能。2020年，又進行了「費米網絡硬分叉」，進一步提高了以太坊的性能和可擴展性。

此外，以太坊2.0的開發也正在進行中。這個版本將引入一個名為「以太坊合併」的重大升級，從目前的工作量證明（PoW）共識機制轉變為工作量證明（PoS）共識機制，以提高效能並節省能源。

以太坊的成功和持續發展使得它成為區塊鏈和加密貨幣領域最重要的項目之一。隨著更多的創新和升級的實施，以太坊正在為區塊鏈技術的應用開啟新的紀元，並為全球數字經濟帶來更多機會和變革，下一頁我們將整理以太坊誕生以及後續相關發展的時間軸。

以下是我們所整理的以太坊的主要里程碑和發展階段：

1. 2008年：比特幣白皮書發布。比特幣是第一個成功實現去中心化加密貨幣的項目，該白皮書由一位自稱中本聰（Satoshi Nakamoto）的人發表。
2. 2013年：年輕的比特幣開發者維塔利克·布特林（Vitalik Buterin）開始對比特幣的區塊鏈技術進行深入研究。他開始寫一些關於區塊鏈技術的文章，並參與一些相關的開發項目。
3. 2013年底：布特林在比特幣開發社區中提出了以太坊的概念。他認為比特幣的區塊鏈應用潛力更廣，應該可以支持更多的功能和智能合約。
4. 2014年1月：布特林和一些合作夥伴成立了以太坊基金會（Ethereum Foundation），該基金會旨在支持以太坊的開發和推廣。
5. 2014年7月：以太坊的種子輪（Seed Round）募集了大約1,200萬美元的資金，用於項目的發展。
6. 2014年8月：以太坊的開發代碼被公開發布，開始進行測試和開發。
7. 2015年7月：以太坊的主網（Mainnet）正式上線，也就是以太坊的基礎網絡啟動運行。這意味著以太坊的區塊鏈網絡開始運作，並可以進行交易和智能合約。
8. 2016年：以太坊的第一個主要升級，被稱為「拜占庭硬分叉」（Byzantium Hard Fork），完成了以太坊區塊鏈的升級和改進。
9. 2017年：以太坊的價值和知名度迅速增長，吸引了更多開發者和企業的關注。同年，以太坊的開發團隊宣布計劃進行一系列的升級，包括改善可擴展性和隱私性。
10. 2018年：以太坊的第二個主要升級，被稱為「康斯坦丁堡硬分叉」（Constantinople Hard Fork），在這次升級中引入了一些改進和新功能。
11. 2020年：以太坊的第三個主要升級，被稱為「費米網絡硬分叉」（Fermat Network Upgrade），旨在提高以太坊的性能和可擴展性。
12. 2021年：以太坊2.0的開發正在進行中，該版本將引入一個稱為「以太坊2.0」或「以太坊合併」的重大升級，該升級將使以太坊從目前的工作量證明（PoW）共識機制轉變為以太坊2.0的工作量證明（PoS）共識機制。

自成立以來，以太坊目前已經成為最受歡迎和廣泛使用的智能合約平台之一，並在區塊鏈和加密貨幣領域中發揮了重要的作用。

2.2 以太坊的特點與應用

以太坊（Ethereum）是一個開創性的區塊鏈平台，具有獨特的特點和廣泛的應用。它的三個主要特點是智能合約、去中心化應用和ERC-20代幣標準。智能合約可在區塊鏈上執行程式化的合約，實現自動化和可信任的交易。去中心化應用（DApps）則使開發者能夠建立各種基於區塊鏈的應用，從金融服務到供應鏈追溯，無需依賴傳統的中心化機構。此外，以太坊的ERC-20代幣標準成為發行和管理代幣的通用標準，推動了代幣經濟的快速發展。這些特點使以太坊成為全球最受歡迎的智能合約平台之一，並在各個領域帶來了革命性的變化。

2.2.1 智能合約

智能合約（Smart Contracts）是以太坊區塊鏈的核心特點之一。它們是在區塊鏈上運行的自動化合約，其中的條件和操作被預先利用程式記錄下來，並以不可更改的方式儲存在區塊鏈上。

智能合約使得雙方能夠在沒有第三方介入的情況下進行可信任的交易和合作。一旦合約條件滿足，合約中的操作將自動執行，以此來實現自動化和無需信任的交易。如此一來消除了傳統合約所需的繁瑣程序和中介機構，提高了效率和可靠性。

智能合約的應用領域非常廣泛。舉例來說，在金融領域，智能合約可以用於創建去中心化金融（DeFi）應用，如借貸、交易和保險，能夠使得這些過程更加透明和高效，改善使用者的體驗。或例如在供應鏈管理中，智能合約可以實現產品的追溯性和真實性驗證，從而提高供應鏈的透明度和準確性。

除此之外，智能合約還可以應用於像是投票、選舉、不動產交易、知識產權保護等等的領域，能夠為各種不同行業的業務流程帶來了革命性的變化，並為傳統中心化系統帶來了挑戰。

然而，智能合約也存在一些挑戰和風險。由於合約的不可更改性，一旦部署後，無法輕易修改或撤銷。因此，在編寫和部署智能合約時，必須非常謹慎，以防止漏洞或錯誤導致損失。除此之外，智能合約的執行受限於區塊鏈的可擴展性和交易速度，這也是需要被解決的問題之一。儘管如此，智能合約作為以太坊的核心功能，為自動化和去中心化的應用打開了大門，為許多行業帶來了革命性的變革機會。

2.2.2 去中心化應用

去中心化應用（Decentralized Applications，簡稱DApps）是建立在以太坊區塊鏈或其他支持智能合約的區塊鏈平台上的應用程式。相較於傳統的中心化應用，DApps的運作並不需要依賴單一中心化機構，而是基於區塊鏈的分散性和共識機制。

DApps 重要特點之一是其去中心化的本質。它們使用智能合約作為程式的基礎，確保交易和操作的透明性、安全性和可靠性。由於智能合約儲存並部署在區塊鏈上，因此它們並不容易被更改或操縱，並且由區塊鏈的共識機制驗證和執行。

去中心化應用擁有多樣化的應用場景。舉例來說，在金融領域，DApps 可用於建立去中心化交易所、借貸平台、穩定幣等，能夠實現更加開放以及透明的金融系統。或在供應鏈管理中，DApps 可追溯產品來源、驗證真實性，促進供應鏈的透明度和可信度。

除此之外，DApps 還能應用在數字藝術市場、社交媒體平台、賭博應用、投票系統等多個領域。它們提供了更加開放、無需信任的環境，使得用戶能夠直接參與和控制其數字資產和數據，從而實現更大程度的自主權和所有權。

然而，去中心化應用仍然面臨著某些挑戰。舉例來說，由於區塊鏈的可擴展性和交易速度限制，DApps 可能面臨效能瓶頸和高交易費用。此外，用戶體驗、安全性和合規性等方面也需要被優化和解決。

儘管存在一些挑戰，去中心化應用仍代表了區塊鏈技術的應用前景，為建立更加開放和公平的數字經濟體系提供了潛力巨大的平台。它們通過消除中心化的權力結構，鼓勵社區參與和創新，推動了數字化社會的發展。

2.2.3 ERC-20代幣標準

ERC-20是以太坊區塊鏈上最常見和廣泛使用的代幣標準之一。ERC-20代幣標準定義了一組規則和接口，用於在以太坊區塊鏈上創建和管理代幣。

使用ERC-20代幣標準，開發者可以輕鬆地發行自己的代幣，並在以太坊區塊鏈上進行交易。這使得代幣的創建和轉移變得非常方便和標準化。ERC-20代幣標準確定了代幣的基本功能，例如代幣的名稱、縮寫、總供應量、精度以及代幣的轉移和餘額查詢等操作。

由於ERC-20代幣標準的廣泛接受和支援，許多加密貨幣交易所、錢包和區塊鏈平台都支援和接受ERC-20代幣。這使得代幣能夠在不同的平台間自由轉移和交易，增加了代幣的流動性和可用性。ERC-20代幣除了可用於ICO（Initial Coin Offering）項目的發行，還能廣

泛應用在去中心化金融（DeFi）應用、遊戲代幣、數字資產代表等領域。它們為數字資產的發行和管理提供了標準化的框架，同時為用戶和開發者帶來了便利和互操作性。

然而，需要注意的是，不是所有在以太坊區塊鏈上發行的代幣都符合ERC-20標準。還存在其他類型的代幣標準，例如ERC-721（非同質化代幣）和ERC-1155（多類型代幣），它們具有不同的特點和用途。

總結來說，ERC-20代幣標準在以太坊生態系統中扮演著重要的角色，為代幣的發行和管理提供了一個通用且互操作的標準。它促進了代幣經濟的快速發展，並在區塊鏈領域推動了更廣泛的創新和應用。

2.3 以太坊的重要性

以太坊的重要性在技術創新和社會影響方面都不可忽視。作為一個開創性的區塊鏈平台，以太坊推動了智能合約、去中心化應用和代幣經濟等領域的發展。其技術創新為建立更加開放、透明和可信任的數字經濟體系提供了基礎，同時在金融、供應鏈、藝術等領域帶來了重大的社會影響。以太坊的重要性不僅體現在技術層面上的創新，還體現在推動全球區塊鏈社區的發展和促進區塊鏈技術應用的普及上。

2.3.1 技術創新

以太坊的智能合約和DApps開放了無限的技術創新空間。開發者可以構建和運行各種各樣的應用，從去中心化金融到供應鏈管理，從不動產記錄到投票系統，實現了去中心化的數字化轉型。

首先，以太坊引入了智能合約的概念，將可程式化的合約代碼儲存在區塊鏈上，使得合約的執行和交易可以自動化、不可更改且可信任。這開啟了一個全新的應用領域，從金融服務到供應鏈管理，甚至社會治理，智能合約的應用無所不在，提供了更高效、安全和可靠的交易方式。此外，以太坊的區塊鏈平台提供了開發和運行去中心化應用的基礎設施。傳統的中心化應用依賴單一機構或中介來管理數據和提供服務，而DApps通過智能合約和區塊鏈的分散性，實現了去中心化的運作方式。這擴展了應用的範疇，讓用戶能夠直接參與和控制自己的數字資產和數據，實現更大程度的自主權和所有權。

此外，以太坊的ERC-20代幣標準成為發行和管理代幣的通用標準，推動了代幣經濟的快速發展。它為數字資產的發行和交易提供了標準化的框架，促進了資產流通性和可用性的提升。代幣經濟的出現創造了新的商業模式和經濟生態，為去中心化金融（DeFi）、數字藝術、遊戲和供應鏈管理等領域帶來了巨大的創新和機會。

總體而言，以太坊在技術創新方面的重要性體現在它推動了智能合約、去中心化應用和代幣經濟的發展，為數字經濟帶來了全新的可能性。這些創新促進了數字資產的流動性、交易的透明度和安全性的提升，並為區塊鏈技術的應用開啟了更廣闊的前景。

2.3.2 社會影響

以太坊的去中心化特性為社會帶來了許多積極的影響。例如，它提供了金融包容的機會，使無銀行帳戶的人可以參與金融交易。它還改善了數字資產的所有權和控制方式，為個人資料的保護提供了新的解決方案。

以太坊在社會影響方面扮演了重要的角色。透過其技術創新，以太坊正在改變傳統金融體系，推動金融革命的浪潮。以太坊的智能合約和去中心化金融（DeFi）應用提供了開放、透明和可靠的金融服務，無需依賴中介機構。這種去中心化的金融系統使得借貸、交易和投資更加高效和可信任，同時提升了金融包容性，讓更多人能夠獲得金融服務的機會。

除了金融領域，以太坊的去中心化應用（DApps）為各行各業帶來了創新和變革的機會。通過智能合約和代幣經濟，DApps提供了更加開放、公平和透明的平台，讓參與者能夠更直接地控制和交互其資產和數據。這為創作者、開發者和用戶帶來了更大的權力和機會，同時推動了去中心化的協作和共享經濟的發展。

以太坊還為社會治理帶來了新的可能性。通過智能合約，可以實現去中心化的投票和決策機制，使得民眾能夠更直接地參與到決策過程中。這種基於區塊鏈的社會治理模式可以提高透明度和信任度，減少中央權力的壟斷，推動社會的民主化和參與度。

最後，以太坊的開放性和全球性使其成為促進全球金融包容性的重要推動力。任何人都可以使用以太坊並參與其中，無需傳統金融機構的中介機構。這為那些無法訪問傳統金融機構的人提供了金融服務的機會，促進了全球金融包容性的提升。

總結來說，以太坊的技術創新和應用在金融、創新、社會治理和金融包容性等方面產生了深遠的社會影響。它推動了金融革命，促進了創新應用的崛起，提供了去中心化的社會治理模式，並為全球數字經濟帶來更大的公平性和機會。

三、LSTM演算法簡介

在機器學習和人工智慧領域，長短期記憶網絡（Long Short-Term Memory，LSTM）被廣泛認識和應用。LSTM是一種特殊的循環神經網絡（Recurrent Neural Network，RNN），具有捕捉長期依賴關係的能力，特別適用於處理時間序列數據。LSTM的出現標誌著在時間序列預測和自然語言處理等領域取得了重要突破。

3.1 LSTM 發展歷程

長短期記憶（LSTM）是一種在深度學習領域中廣泛應用的循環神經網絡（RNN）架構。在RNN的限制日益顯著的情況下，LSTM的提出標誌著一個重要的技術突破。LSTM被設計出來解決RNN中存在的長期依賴性和梯度消失等問題。自其提出以來，LSTM不斷演進和改進，成為一種強大且廣泛應用的神經網絡模型。

在探討LSTM的發展歷程之前，有必要了解RNN的限制。傳統的RNN在處理長序列數據時常常遭遇梯度消失或梯度爆炸的問題，這限制了其對長期依賴性的建模能力。此外，RNN的記憶能力有限，難以捕捉長期記憶和長期相依的信息。

為了克服RNN的限制，於1997年，LSTM被提出作為一種特殊的RNN架構。LSTM引入了記憶單元和門控機制，以更好地捕捉和管理長期的時間相依性。這種網絡架構具有自適應的記憶單元，可以選擇性地遺忘、更新和輸出信息，並且能夠有效地保持梯度的流動。

隨著LSTM的提出，研究人員開始對其進行改進和擴展，以應對不同的任務和挑戰。出現了许多變體和衍生模型，如雙向LSTM、門控循環單元（GRU）等，這些模型在保留LSTM的核心特點的同時，提供了更高的性能和靈活性。LSTM作為一種強大的循環神經網絡模型，彌補了傳統RNN的限制，並成為處理序列數據和時間相依性的重要工具。其提出和演進為深度學習在自然語言處理、語音識別、時間序列分析等領域帶來了重大的影響和創新。隨著技術的不斷發展，LSTM將繼續在人工智慧領域中發揮著關鍵的作用。

3.1.1 RNN的限制

傳統的循環神經網絡（RNN）在處理長序列數據時存在一些限制，這些限制影響了其在實際應用中的表現：

1. 梯度消失和梯度爆炸：在RNN中，梯度的計算是通過時間步的連鎖法則進行的，梯度在每個時間步都要進行乘法和累積。當序列長度增加時，梯度的值可能會指數級增長或指

數級減少，這稱為梯度爆炸和梯度消失。梯度消失使得模型難以捕捉長期的依賴關係，而梯度爆炸則導致模型難以穩定地訓練。

2. 短期記憶：RNN的記憶能力有限，僅能夠將相對較近的信息納入考慮。當序列長度增加時，較早的信息容易被忘記，這限制了RNN對長期依賴關係的建模能力。在某些應用中，如自然語言處理中的長句子理解或股價預測中的長期趨勢分析，這一限制尤其顯著。

3. 參數共享：在傳統的RNN中，所有時間步之間的權重共享，這意味著所有的時間步都使用相同的權重矩陣。這種參數共享對於捕捉不同時間步之間的差異和變化非常有限，導致模型在處理複雜的時間序列模式時表現不佳。

這些限制限制了傳統RNN在處理長序列數據和捕捉長期依賴關係方面的表現。為了克服這些限制，LSTM模型應運而生，通過引入記憶單元和門機制等結構，使得模型能夠有效地捕捉和記憶長期的時間依賴關係，並解決了梯度消失和梯度爆炸的問題。這使得LSTM成為處理時間序列數據的首選模型之一。

3.1.2 LSTM的提出

LSTM於1997年由Sepp Hochreiter和Jurgen Schmidhuber提出，作為對傳統RNN限制的一種改進。LSTM的提出旨在解決RNN在處理長序列數據時遇到的梯度消失、梯度爆炸和短期記憶等問題。

LSTM引入了記憶單元（memory cell）和門機制（gate mechanism），這些結構賦予了LSTM捕捉和記憶長期依賴關係的能力。

1. 記憶單元：LSTM的核心是記憶單元，它負責記憶和傳輸信息。記憶單元可以存儲和更新狀態，以捕捉和記憶長期的時間依賴關係。記憶單元的結構類似於一個狀態單元，其中信息可以長時間地存儲和更新。

2. 門機制：LSTM通過門機制（如遺忘門、輸入門和輸出門）控制信息的流動和記憶的更新。這些門機制由sigmoid函數和逐點乘法運算組成，可以根據輸入和先前的狀態決定要遺忘、保留和更新的信息。


3. 遺忘門：遺忘門控制著記憶單元中的信息被遺忘的程度。它通過計算先前的狀態和當前的輸入，決定要從記憶單元中遺忘的信息。

4. 輸入門：輸入門決定要從當前輸入中提取的信息。它通過計算先前的狀態和當前的輸入，決定要存儲在記憶單元中的新信息。

5. 輸出門：輸出門控制著要輸出到下一層或作為預測結果的信息。它通過計算先前的狀態和當前的輸入，決定記憶單元中的哪些信息應該被輸出。

這些結構和門機制使得LSTM能夠在模型中動態地記憶、遺忘和更新信息，從而捕捉和記憶長期的時間依賴關係。LSTM的引入使得模型能夠更好地處理長序列數據，並在時間序列預測、自然語言處理和其他領域取得了顯著成果。

透過LSTM的演進，還出現了一些變體，如雙向LSTM、多層LSTM和注意力機制等，進一步增強了LSTM在處理時間序列數據中的表現能力。這些變體擴展了LSTM的應用範圍，使其在更多領域發揮重要作用。



圖（一）、LSTM模型架構[來源：6]

3.1.3 LSTM的演進

隨著深度學習和神經網絡領域的發展，LSTM模型也得到了進一步的改進和擴展。下面列舉了一些LSTM的演進方面：

1. 多層LSTM：傳統的LSTM模型由單層組成，但為了提升模型的表達能力和學習能力，研究者們開始堆疊多個LSTM層來構建深層網絡結構。多層LSTM模型通過將多個LSTM層疊加在一起，使得模型能夠處理更複雜的時間序列模式，同時增加了模型的非線性能力和表達能力。

2. 雙向LSTM：傳統的LSTM模型是單向的，它只能從過去的序列預測未來。然而，在某些應用中，過去和未來的信息都對當前預測有影響。為了解決這個問題，研究者們引入了

雙向LSTM模型，它同時考慮了過去和未來的序列信息。雙向LSTM由兩個獨立的LSTM組成，一個負責正向傳播，另一個負責反向傳播，最終將兩個方向的結果進行結合。

3. 注意力機制：在傳統的LSTM模型中，所有的時間步的輸入都平等地參與計算和決策。然而，在某些情況下，不同時間步的重要性不同，有些時間步的信息對預測結果的貢獻更大。為了解決這個問題，注意力機制被引入到LSTM模型中。注意力機制使得模型可以自動學習和選擇不同時間步的重要性，從而更好地捕捉和利用時間序列中的關鍵信息。

4. 長短期記憶標準化 (LSTM Normalization)：LSTM模型在長序列數據上的訓練過程中可能遭遇數值不穩定的問題。為了增強模型的訓練穩定性和收斂速度，研究者們提出了LSTM標準化方法，例如Layer Normalization和Batch Normalization等。這些方法通過對LSTM模型的隱藏狀態和輸出進行標準化處理，提高了模型的訓練效果和性能。

這些LSTM的演進方面使得LSTM模型更加強大和靈活，擴展了其在時間序列預測、自然語言處理和其他領域中的應用範圍。研究者們不斷探索和改進LSTM模型，希望進一步提升其性能，使其更好地適應不同的應用場景。

3.2 LSTM 特點

3.2.1 長期依賴關係：LSTM通過記憶單元的結構和門機制，能夠有效地捕捉和記憶長期的時間依賴關係。這使得LSTM在處理時間序列數據時具有顯著的優勢。

3.2.2 梯度穩定性：相比傳統的RNN，LSTM通過門機制的引入，解決了梯度消失和梯度爆炸的問題，使得模型的訓練更加穩定和可靠。

3.2.3 多層結構：LSTM可以透過堆疊多個LSTM層來構建深層網絡結構，從而增加模型的表達能力和學習能力。多層LSTM的結構使得模型能夠處理更複雜的時間序列模式。

3.3 LSTM 重要性

長短期記憶網絡 (Long Short-Term Memory, LSTM) 作為一種特殊的循環神經網絡 (Recurrent Neural Network, RNN)，已經成為一個引人注目且不可或缺的工具。LSTM的出現在解決時間序列預測、自然語言處理和人工智慧應用中取得了重要的突破，為我們帶來了許多新的機會和挑戰。

1. 時間序列預測：時間序列預測是LSTM模型的一個重要應用領域。LSTM具有捕捉長期依賴關係的能力，使其在時間序列預測中表現優異。例如，在金融領域，LSTM被廣泛應用

於股價預測、外匯市場分析和加密貨幣價格預測等。透過學習過去的趨勢和模式，LSTM能夠捕捉到時間序列中的非線性和複雜關係，提供準確的預測和洞察力。

2. 自然語言處理：自然語言處理是另一個LSTM的重要應用領域。LSTM能夠處理文本序列的建模和生成，使其在語言翻譯、情感分析、語音識別和文本生成等任務中取得了顯著的成果。LSTM通過捕捉語言的上下文和語義信息，能夠更好地理解 and 生成自然語言，提高了自然語言處理的效能和準確性。

3. 人工智慧應用：隨著人工智慧技術的迅速發展，LSTM成為了許多人工智慧應用的核心技術之一。在對話系統中，LSTM能夠模擬和生成自然對話，使得對話更加流暢和自然。在影像識別和處理中，LSTM能夠處理圖像和視頻序列，從而在圖像描述生成、動作識別和視頻分析等任務中發揮重要作用。此外，LSTM還被廣泛應用於音樂生成、自動駕駛和機器人控制等領域，推動了人工智慧的發展和應用。

LSTM在時間序列預測、自然語言處理和人工智慧應用中的重要性不言而喻。其能夠捕捉長期依賴關係、處理序列數據的能力，使其成為解決這些領域中的複雜問題的有效工具。隨著LSTM的不斷演進和改進，我們可以預見LSTM在更多領域的廣泛應用和影響，為我們帶來更多的可能性和創新。

四、實驗設計

這個部分我們將介紹我們在預測幣價實作方面的細節，包括：幣價資料來源、完整程式碼以及結果分析與未來研究。

4.1 資料來源

本次我們所使用的以太坊－美元的資料來源為Yahoo Finance，除了以太坊－美元之外，我們也利用了狗狗幣(Doge Coin)來進行幣價的預測來進行比較，其幣價的資料來源也為Yahoo Finance。我們所選擇的幣價範圍為五年，且時間週期為一天。我們將幣價資料以CSV格式下載下來後，透過Pandas進行前期處理，再執行正歸化後，最後丟入模型進行預測模型。

4.2 程式碼

以下為實作程式碼的截圖：

```
[ ] import numpy as np
import pandas as pd
import tensorflow.keras
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import LSTM, Dense
from sklearn.preprocessing import MinMaxScaler
```

```
[ ] df = pd.read_csv('DOGEUSD.csv')
```

```
[ ] def Min_Max_normalization(name):
    #調整維度成[[資料1],[資料2]]
    name = name.reshape(-1, 1)
    #正規化數值
    scaler = MinMaxScaler(feature_range=(0, 1)).fit(name)
    sc = scaler.transform(name)

    #[維度還原]
    return sc.reshape(-1)

#df[row]:可以直接取一整排的數值回傳的type是dataframe
#values:轉成dataframe轉成array
open_p = Min_Max_normalization(df['Open'].values)
max_p = Min_Max_normalization(df['High'].values)
min_p = Min_Max_normalization(df['Low'].values)
fin_p = Min_Max_normalization(df['Close'].values)

#replace(old,new)這裡是將文字中的,去掉
#len_p = np.array([int(i.replace(',','')) for i in df['Volume'].values])
len_p = Min_Max_normalization(df['Volume'].values)
```

```
[ ] data = []
tmp = []
label = []
#最後一筆label的範圍是最大數量-11天
for cnt in range(len(open_p)-11):
    #獲取10天的資料
    open_10 = open_p[cnt:cnt+10]
    max_10 = max_p[cnt:cnt+10]
    min_10 = min_p[cnt:cnt+10]
    fin_10 = fin_p[cnt:cnt+10]
    len_10 = len_p[cnt:cnt+10]

    #zip可以將每筆資料都同時丟進for迴圈中
    for i,j,k,m,n in zip(open_10,max_10,min_10,fin_10,len_10):
        tmp.append([i, j, k, m, n])
    data.append(tmp)
    tmp = []
    #取得收盤價
    label.append(fin_p[cnt+11:cnt+12][0])
```

```
[ ] split_cnt = int(len(data)*0.8)
x_train,y_train = np.array(data[0:split_cnt]),np.array(label[0:split_cnt])
x_test,y_test = np.array(data[0:len(data)-split_cnt]),np.array(label[0:len(data)-split_cnt])
```

```
[ ] model= Sequential()
model.add(LSTM(128,input_shape=(10, 5),return_sequences=True,activation='relu'))
model.add(LSTM(64,return_sequences=False,activation='relu'))
model.add(Dense(1))
#mse為跑回歸任務的其中一個loss function
#回歸任務沒有acc只有loss
model.compile(loss='mean_squared_error',optimizer='adam')
# 開始訓練model batch_size一次丟多少資料進去訓練 epochs總共要訓練幾次
history = model.fit(x_train, y_train,
                    batch_size=128,
                    epochs=1000,
                    verbose=1,
                    validation_data=(x_test, y_test))
```




```
[ ] import matplotlib.pyplot as plt

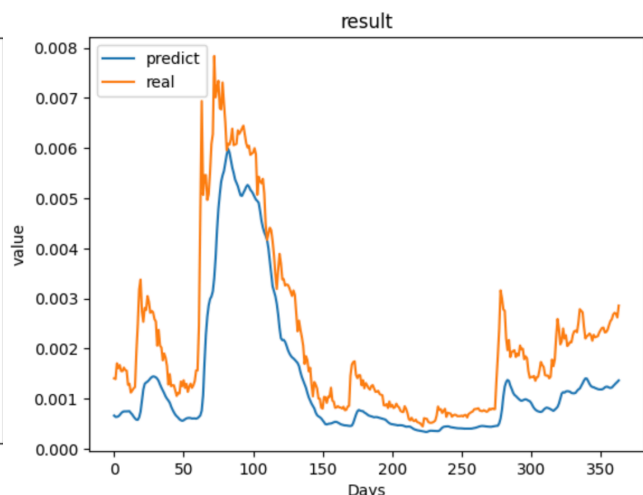
y_predicted = model.predict(x_test)
#預測
plt.plot(y_predicted)
#實際值
plt.plot(y_test)
#標題
plt.title('result')
#y軸標籤
plt.ylabel('days')
#x軸標籤
plt.xlabel('value')
#顯示折線的名稱
plt.legend(['predict', 'real'], loc='upper left')
#顯示折線圖
plt.show()
```

4.3 結果分析


我們在實作的部分進行了四次的模擬，分別利用 ETH、DOGE 在 batch size=300、epochs=100以及batch size = 300、epochs=1000的情況下共進行了四次的模擬，奇摩你幣價預測結果如下四張圖所示：



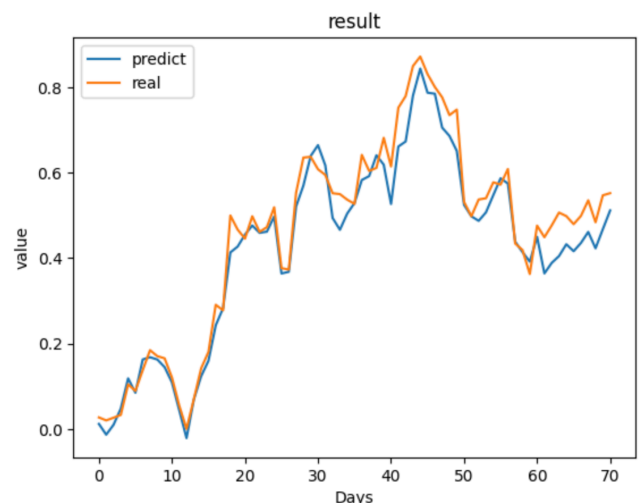
圖（二）、Doge Coin預測結果(epochs=100)



圖（三）、Doge Coin預測結果(epochs=100)



圖（四）、ETH預測結果(epochs=100)



圖（三）、ETH預測結果(epochs=1000)

如上四圖所示，可以發現在相同的幣種情況下，epochs=1000比起epochs=100的情況下的預測情況來的準確許多，導致這種情況的原因我認為有可能是因為增加了訓練迭代次數（epochs）使得模型更好地學習和適應訓練數據。而訓練迭代次數增加時，能使得模型有更多機會進行權重更新和調整，進一步優化模型的性能。會有這樣的結果可能有三個原因：包括更多的學習時間、減少過擬合以及能夠有更好地收斂：

1. 更多學習時間：增加epochs意味著模型將對訓練數據進行更多次的學習和適應，進一步細化模型對數據的理解和表示。

2. 減少過擬合：通常，增加epochs可以幫助減少模型的過擬合現象。適當的訓練迭代次數使模型能夠更好地捕捉數據中的模式和趨勢，同時避免對訓練數據的過度擬合。

3. 更好的收斂：LSTM模型通常需要更長的時間才能達到良好的收斂狀態。增加epochs可以提供足夠的時間，使模型能夠更好地收斂到最佳權重和參數配置。

除此之外，我們在epochs相同的情況下，觀察不同幣種的預測結果，會發現ETH的幣價預測相較Doge Coin來的更接近，我想會造成這樣子現象的原因是因為Doge Coin的幣價較低（0.00多），因此只要有些許的誤差，其與真實幣價的相對誤差就會被放大；而以太幣的幣價較高（幾千多美元），因此即便仍有誤差，其相對誤差也不會那麼大。除此之外，我們認為市場流動性也有部分的影響：低價幣種通常具有較低的市值和流動性，這意味著交易量相對較小，價格變動可能更受限制。因此，即使有較小的預測誤差，它也可能對低價幣種的價格產生較大的影響。相比之下，高價幣種具有較高的市值和流動性，因此較小的預測誤差可能會被市場更快速地消化和調整。再者，市場風險和波動性也是造成如此結果的原因之一：低價幣種通常伴隨著更高的市場風險和價格波動性。這種不穩定性可能增加預測的挑戰性，導致更大的預測誤差。相比之下，高價幣種由於市場規模較大，因此可能相對穩定，波動性較小，這對預測的準確性有所助益。

五、結論與未來研究

本篇報告旨在探討使用LSTM神經網路模型預測以太幣（以及狗狗幣）幣價的能力。通過分析以太幣的歷史價格數據並利用LSTM模型，獲得了一些有價值的結果和洞察。

在我們的實作中，LSTM模型展現出了在預測加密貨幣幣價方面的潛力和效能。我們的結果顯示，LSTM模型能夠捕捉到以太幣價格中的複雜模式和趨勢，並提供了準確的預測。這為投資者、交易者和研究人員提供了一個重要的參考工具，幫助他們做出更明智的決策。

然而，我們也要意識到LSTM模型在預測以太幣幣價方面存在一些限制和挑戰。首先，模型的預測結果受到數據品質和數據覆蓋範圍的限制。因此，為了提高預測的準確性和可靠性，我們建議使用更大規模的數據集並仔細選擇相關的特徵。其次，LSTM模型在處理極端市場條件和突發事件時可能會面臨困難，這需要進一步的研究和改進。

基於本研究的結果，我們認為未來能有些許的修正以及更進一步的研究，包括：

1. 擴展數據集：使用更長的時間序列數據和更多的相關特徵，以提高模型的預測能力和穩定性。
2. 考慮多模型組合：將LSTM模型與其他預測方法（如ARIMA或混合模型）進行組合，以提供更全面和準確的預測結果。
3. 持續優化模型：進一步研究和優化LSTM模型的架構、參數和超參數配置，以提高模型的性能和適應性。
4. 引入外部因素：考慮將外部因素（如市場指標、新聞事件）納入模型，以更全面地捕捉到以太幣價格的影響因素。

總的來說，我們相信LSTM神經網路模型在預測以太幣幣價方面具有重要的應用價值。這份報告為進一步探索和應用LSTM模型在加密貨幣領域提供了基礎，並為相關研究提供了啟示和指導。

參考資料：

[1]Forecasting Cryptocurrency Prices Using LSTM, GRU, and Bi-Directional LSTM: A Deep Learning Approach

by Phumudzo Lloyd Seabe 1,*,Claude Rodrigue Bambe Moutsinga 1 andEdson Pindza 2

[2]A NEXT GENERATION SMART CONTRACT & DECENTRALIZED APPLICATION PLATFORM By Vitalik Buterin

[3]遞歸神經網路 (RNN) 和長短期記憶模型 (LSTM) 的運作原理 https://brohrer.mcknote.com/zh-Hant/how_machine_learning_works/how_rnn_lstm_work.html

[4] Yahoo Finance ETH-USD history price
<https://finance.yahoo.com/quote/ETH-USD/history?period1=1623974400&period2=1687046400&interval=1d&filter=history&frequency=1d&includeAdjustedClose=true>

[5] Yahoo Finance Doge-USD history price
<https://finance.yahoo.com/quote/DOGE-USD/history?period1=1529366400&period2=1687132800&interval=1d&filter=history&frequency=1d&includeAdjustedClose=true>

[6] https://d2mk45aasx86xg.cloudfront.net/image17_11zon_2727417658.webp